基于深度学习的 Micro-C 接触矩阵分析

三项必做 + 三项选做 · 完整实验报告

数据：大肠杆菌 MG1655 · GEO GSE272159 | 版本：2026-09-28

结果总览

任务一	接触+已知区间 CNN 五折宏 F1 0.756、CHID 精确率/召回率 0.632/0.462；仍低于边界混合模型，归因有限。
任务二	已知合并位点召回 88.4%；三位点 rep2 新颖性 3/3，但同批背景 13/100，未确证新类型。
任务三	覆盖全基因组的 465 张 10 kb 多轨道图，附原始图像清单与哈希。
任务四	44℃/利福平/H-NS 三种子交集分别为 17/98/82 条注释；均是探索性候选，H-NS 有平台混杂。
任务五	4 倍模拟超分辨 PSNR 提升约 2 dB；独立峰排序 top5 命中率跨重复提高，top1 仍不稳健。
任务六	五随机种子 WT rep2 相关 0.706–0.716；精确间距 AUC 均未超过 MDS 0.753；无三维真值。

证据边界：本报告如实保留未通过的阈值、少数类识别、跨条件迁移、热点定位和三维基线对照；计算候选不等同于已证实的新生物学结构。完整数据来源、代码、逐样本指标及权重可由仓库链接复核。

设计思路

本项目以大肠杆菌 MG1655 的 10 bp Micro-C 接触矩阵为输入，按课程方案完成三项必做及三项选做任务。核心开放问题是：在 OPCID、CHIN、CHID 的 344 条注释之外，能否找到可复现且形态不同的局部接触模式？“新结构”在此仅指满足明确计算规则的未注释候选，不等同于新的生物学实体。原始矩阵来自 NCBI GEO GSE272159；注释来自课程工作簿 Supplementary Tables 4/5/6。原始数据的文件哈希见 provenance.json。

项目首先用两个独立 WT 37°C 重复完成已知结构训练与全基因组发现，再用跨重复、错位窗口、背景样本和阈值敏感性对照验证候选。可选任务分别采用两条件重复配对、模拟降分辨率超分辨，以及全基因组三维坐标优化。方法细节及复跑命令见 METHODS.md 和 README.md。

方法选择与对照实验

任务	方法与设计选择	主要对照
1 已知结构识别	类别加权 CNN；按不重叠基因组邻近组划分训练、验证、测试；另做重叠感知 CHID 五折交叉预测	空间隔离混淆矩阵；CHID 中心单标签与邻近存在检测分开评价
2 候选发现	全基因组切窗、距离归一化、自编码器异常分数、形态与密度融合、PCA/KMeans	已知结构召回；空间留出且跨重复的已知/背景分类；密度单特征；远距离与邻近错位零分布；严格阈值
3 多轨道图	10 kb 连续区间，四面板叠加 WT、44°C、利福平与基因/结构注释	全长覆盖数量与代表性图像核查
4 条件变化	两个 WT 与两个处理重复；原始计数聚合后二项抽稀到共同测序深度；比较局部归一化强度	WT 重复对照、重复方向一致性、内部重复波动第 95 百分位；44°C 与低深度利福平分开报告
5 超分辨	4 倍原始计数合并形成低分辨率输入；输入与目标各自归一化；残差块 CNN；基因组区段留出	双线性插值、成对 PSNR/SSIM、块自助法区间、已知结构中心恢复
6 三维重建	5 kb 全基因组分箱；不使用 MDS 先验的神经坐标优化	独立 MDS 基线、弱 MDS 正则消融、反算接触图

评价指标与结果

任务一：已知结构识别

原默认 CNN 对照：严格空间隔离的 69 个留出结构、两个重复共 138 个样本上，准确率 0.870、宏 F1 0.599。混淆矩阵 显示 CHIN/OPCID 的 F1 为 0.916/0.880，但 CHID 的 F1 0（12 个测试样本无一识别）。这意味着总体准确率乐观、少数类表现却不合格，不能声称三类都稳定识别。按验证集试验把 CHID 损失权重加倍后，验证集宏 F1 仅从 0.620 微升到 0.622，测试集准确率/宏 F1 反降至 0.826/0.557；不采用该变体。空间隔离指标、显著性图及分区审计已保存。

显著性证据审计：原 CHID 图在没有正确分类样本时回退到“真实类型为 CHID 但预测错误”的样本，不能作为 CHID 被识别的证据。现在图题显式标明 12/12 个 CHID 测试样本均误判为 CHIN。进一步以同对角距离的非注释像素作背景，比较真实类别 logit 的输入梯度在注释方块内的富集：正确分类结构的中位数为 CHIN 0.975（41 个可评价结构）、OPCID 1.066（8 个）；均没有显示强而稳定的结构内归因。CHID 没有正确分类样本可做这一检验，且多数

CHID 注释比 5.12 kb 输入窗更宽。这一审计不能支持“模型主要关注结构而非背景”的强说法；逐样本表与摘要给出全部分母和限制。

在相同的 10.24 kb 隔离分区上，5.12 kb/10.24 kb 观察窗的验证宏 F1 为 0.631/0.651；对应测试准确率 0.684/0.816，但测试宏 F1 0.606/0.547，CHID 召回率 0.400/0。宽窗口牺牲了少数类，且这个分区与上面的 5.12 kb 主实验不同，不能把两个测试集当作同一批样本比较。这里只是探索性分析，不以测试集回头挑模型；窄窗和宽窗的完整指标均保留。

另试保留 4×4 空间布局的 CNN 末层，以减少全局平均池化对相对位置的抹除。同一 5.12 kb 空间分区上，验证宏 F1 从 0.620 增至 0.674，但测试准确率/宏 F1 从 0.870/0.599 降至 0.725/0.550；CHID 只识别出 2/12，精确率 0.100。该探索性变体说明位置特征可能有用，但当前样本量下泛化不可靠，不替换主模型。测试集已经多次用于透明诊断，今后的模型选择需要重新设立独立区域或嵌套交叉验证，不应再把现有测试集称为从未查看的留出集。

旧版按结构 ID 分组的准确率 0.746、宏 F1 0.642、CHID 精确率/召回率 0.185/0.500，只保留作对照。旧分区的额外类别阈值使测试准确率/宏 F1 降至 0.645/0.564；10.24 kb 宽窗口使验证宏 F1 从 0.589 降至 0.566。这些旧分区实验均不能作为空间独立性能证据；记录见旧版指标、校准试验和宽窗口试验。

分类评估审计：旧版 69 个测试注释中有 45 个与另一分区的注释中心相距不足 5,120 bp，导致输入窗口可能重叠；审计数据可复核。新版以相邻中心间距小于一个完整输入窗口的连通分组划分，所有分区之间的最近中心距离均超过 5,120 bp。26 个 CHID 中有 25 个距离某个 CHIN 中心不足 5,120 bp，其中 19 个不足 1 kb；固定窗口的单标签分类本身存在相邻结构混合问题。空间隔离成绩作为可靠对照，但它并未解决 CHID 样本稀少及邻近 CHIN 注释造成的可分性问题。

重叠感知的补充任务：把标签预先定义为“注释中心 ±1 kb 内是否存在 CHID”，56/344 个中心为阳性，并用互不重叠的基因组连通组做五折交叉预测。该二分类模型的平均精确率 0.404（空间组自助法 95% 区间 0.256–0.569，阳性基率 0.163），固定 0.5 阈值下精确率/召回率 0.329/0.500。若仍用原来的“中心注释本身是 CHID”计分，同一预测的精确率为 0.153，并没有解决原单标签任务。这是一个不同、更加符合邻近结构共存的检测任务，绝不与旧版 0.185 精确率直接比较；五折预测、指标及不确定性可复核。

原单标签任务的进一步改进：26 个 CHID 中有 17 个注释跨度超过 5.12 kb。为排除位置泄漏，按更保守的 20.48 kb 邻近组做五折交叉预测，固定训练 12 轮，不从外层测试折选阈值。使用 GroupNorm 的 5.12 kb 局部 CNN 达到总体准确率 0.826、宏 F1 0.630；CHID 精确率 0.417（5/12）、召回率 0.192（5/26），空间组自助法的精确率 95% 区间 0.125–0.750。它在原标签下比旧版 0.185 更有希望，但评估划分不同、区间很宽，不能把差值当作已证实提升；尤其两折完全没有报出 CHID。对 24 对邻近 CHID–CHIN 加排序约束，精确率由同折对照 0.231 降至 0.190；同一 20.48 kb 分区上加入 20.48 kb 接触图通道，精确率由 0.417 降至 0.235、宏 F1 从 0.630 降至 0.591，均不采用。完整五折指标、逐结构预测、不确定性、失败的成对对照和最终训练权重随分支提供。最终权重用全部 344 条标注训练，只用于推理，性能以五折结果为准。CHID 的低召回和标注重叠仍是未解决的局限。

已知区间分类的可用改进：保留原始 CHIN/OPCID/CHID 三分类标签，用更严格的 40 kb 空间连通组做五折交叉预测。单看标注跨度的逻辑回归得到 CHID 精确率/召回率 0.348/0.615；单看接触图的 GroupNorm CNN 为 0.217/0.192，将跨度直接接入 CNN 为 0.294/0.192，后者仍不如长度基线。改用两个 WT 重复的接触形态特征均值加已知区间跨度、类别加权的直方图梯度提升，达到准确率 0.866、宏 F1 0.721、CHID 精确率 0.588（10/17）、召回率 0.385（10/26）。同折的接触形态单独模型为 0.500/0.115，跨度单独模型为 0.308/0.615；因此提升不是单纯利用区间长度。40 kb 空间组自助法给出 CHID 精确率 95% 区间 0.333–0.800，样本仍少。另三个 40 kb 折种子的精确率/召回率在 0.563–0.647/0.346–0.423，三个 20 kb 折种子为 0.458–0.611/0.423。全部六种形态/跨度模型的同折指标、逐结构交叉预测、不确定性及最终模型均保留；最终模型以全部 344 条标注训练，不以训练分数报告泛化。该方法并非纯深度学习模型，且跨度只在已知区间有定义，不能用于无标注区域扫描；多个方案的后验比较也需要新的独立标注集验证。

若更重视少漏检，在每个外层训练集内再做三折空间交叉预测选择 CHID 阈值，完全不使用外层测试标签选阈值；五个外层折汇总的 CHID 精确率/召回率变为 0.386/0.654（17/44 个预测为真、17/26 个真 CHID 找回），准确率 0.840、宏 F1 0.721。这是一项更高召回、误报更多的取舍，并非同时改善所有指标；逐折阈值和外层预测已保留。最终模型的部署阈值另由全部训练标注内部的空间交叉预测选择，不把其训练集表现充当测试成绩。推理脚本已和训练时的 4×4 原始计数聚合核对，344/344 个已知区间的模型预测一致。

进一步的边界感知模型：针对 CHID 常宽于 5.12 kb 的问题，从独立归一化的 20.48 kb 接触图提取已知区间内部、两侧及跨边界接触，与 5.12/20.48 kb 形态和区间跨度合用。40 kb 隔离五折的准确率 0.895、宏 F1 0.787、CHID 精确率 0.600（15/25）、召回率 0.577（15/26）。同折短尺度模型为 0.866/0.721/0.588/0.385（依次为准确率、宏 F1、CHID 精确率、召回率）；CHID 召回差 +0.192，配对空间组重采样 95% 区间 +0.030 至 +0.400，宏 F1 差的区间 −0.007 至 +0.148，不能宣称整体提升已被独立证实。另三个 40 kb 折种子的 CHID 精确率/召回率为 0.500–0.600/0.462–0.577，三个 20 kb 折种子为 0.483–0.556/0.538–0.577；召回改善较一致，精确率并非每次都改善。直接拼接多尺度特征以及短/长模型等权概率平均的对照不稳定，均不替代边界模型。全部同折对照、逐结构预测、配对不确定性、最终模型可复核。最终模型用全部 344 条标注训练，推理预处理与缓存数据 344/344 一致。它仍依赖已知区间的起止坐标，不能直接扫描未知结构；仅 26 个 CHID 且多次后验模型比较，仍需要独立标注集。

WT 生物学重复迁移审计：固定同一 40 kb 空间五折、只以 rep1 特征训练而在 rep2 的留出位点测试，CHID 精确率/召回率 0.500/0.500、宏 F1 0.762；反向 rep2→rep1 为 0.455/0.385、宏 F1 0.714，两重复联合为 0.600/0.577、宏 F1 0.787。在另一 40 kb 折种子和 20 kb 分区中也出现方向不对称；两重复联合不是每次都优于单向迁移。全部模式与逐结构预测已保留。这说明部分成绩受具体重复影响；它是同一套标注的技术/生物重复稳健性审计，不是独立标签集的外部验证。

纯 CNN 类别不平衡补充试验：在同一 40 kb 空间五折、只输入接触图、固定 12 轮的设定下，把训练折内类别权重从平方根逆频率改为完全逆频率。CHID 召回提高到 0.385（10/26），但精确率降为 0.159（10/63），总体准确率/宏 F1 为 0.721/0.578；过多 CHIN 被误报为 CHID。故不采用该变体，也不能用它宣称纯 CNN 已稳定完成三类识别。逐结构预测与混淆矩阵摘要保留为失败对照。

验证集选模的纯 CNN 再试验：固定既有 206/69/69 条训练 / 验证 / 测试空间分区，预列四个仅输入接触图的 GroupNorm CNN 候选，只用验证区结构级宏 F1 选模型和轮次。选中模型验证宏 F1 为 0.703、CHID 找回 3/5；但同一测试区结构级准确率 / 宏 F1 为 0.754/0.570，CHID 仅找回 1/6、精确率 1/9=0.111。原 CNN 在此同折为 0.870/0.599、CHID 0/6。新模型虽多识别一条 CHID，却使整体表现退步，不能替换主模型；两 WT 重复的结构级预测 66/69 一致。测试折此前已公开，这只是透明探索，不可继续用它挑选方案。四候选与测试摘要、逐结构预测、逐重复预测及试验权重均保留。

同折深度学习改良：在同一组更保守的 40 kb 空间连通五折中，预先固定 12 轮和四路输入；每折训练不使用该折测试标签调参，但最终架构依据这四路比较回顾性选定：短接触图 CNN 的准确率/宏 F1 为 0.797/0.595、CHID 精确率/召回率 0.217/0.192；盲加长尺度接触为 0.797/0.571/0.167/0.115；只给已知区间方框与跨边界掩膜为 0.741/0.561/0.370/0.385；双接触图加区间掩膜达到 0.872/0.756/0.632/0.462（CHID 正确 12/26）。后一模型相对仅区间掩膜的宏 F1 增益 0.196，40 kb 空间组成对自助 95% 区间 [0.124, 0.267]；CHID 精确率增益 0.261，区间 [0.073, 0.500]，说明接触图对总体与 CHID 精确性提供额外信息，但 CHID 召回增益区间跨零。同折边界特征 +GBM 仍为宏 F1 0.787、CHID 0.600/0.577，新 CNN 的宏 F1 差 −0.031、区间 [−0.106, 0.047]，不能宣称超过它。四路同折指标、同折含混合模型对照及置信区间、逐结构预测和消融混淆矩阵可复核。这是已知起止点分类；区间掩膜不能用于无标注区域的新结构扫描。最终模型分数有选型偏倚，且这些标签及折曾用于先前探索，不是全新独立验证。

新 CNN 的归因边界：外折模型逐项置中位值时，去掉全部接触通道使宏 F1 从 0.756 降至 0.257；去掉区间掩膜使其降至 0.495、CHID 召回为 0。置零有分布偏移，故又在长接触图同对角距离、等数量像素比较区间内外遮挡：CHID 仅 15/26 条的区间内遮挡导致更大真实类边际下降。CHID 接触梯度的区间内相对同距离背景中位富集 1.34，21/26 条大于 1，但三类正确留出实例中 OPCID 的富集只有 0.62。因此网络确实使用接触和区间信息，却未证明三

类都稳定聚焦结构而非背景，更不能把 CHID 提升全归于形态。遮挡逐样本与摘要、聚合诊断图和三类留出显著性图保留。全 344 条标注训练的推理权重与通道元数据不提供训练集泛化成绩。

辅助标注加分项：新增离线人工复核页，将任务二的 7 个独立位点、两重复热图、重复相关、距已知注释距离及任务一 CNN 对已知三类形态的提示放在同一页面。审阅者可逐位点填写“保留候选 / 更像已知类 / 疑似噪声”和备注，导出 JSON；原始矩阵和选择不上传。CNN 对这些未注释窗口属于分布外推断，尤其 CHID 识别薄弱，所示分数不是候选为新结构的概率，页面不会自动给出新颖性结论。模型提示表和生成脚本可复核。

训练折内选型的防高估复核：再把三种预列边界特征组合与四个 CHID 阈值放在每个 40 kb 外层训练折内部三折选择，不看该外折测试标签；27 个空间连通组为成对自助单位。主划分中嵌套选型的准确率/宏 F1 为 0.881/0.764，CHID 精确率/召回率 0.500/0.577，未超过同折固定边界模型的 0.895/0.787、0.600/0.577；宏 F1 成对差 −0.023，95% 区间 [−0.061, 0.017]。改变划分随机种子的敏感性中，嵌套/固定宏 F1 为 0.761/0.738，CHID 召回 0.615/0.462，但精确率 0.457/0.500，宏 F1 差区间 [−0.013, 0.070] 仍跨零；344 条注释中仅 10 条改变外折归属，这不是独立外验。第三个种子与主划分完全相同，未重复计数。故无法以诚实嵌套选型证明进一步全面提升，也不以主划分上后验最好的 0.787 宣称可稳定迁移。主划分摘要、敏感性摘要与逐注释外层预测保留所有取舍。

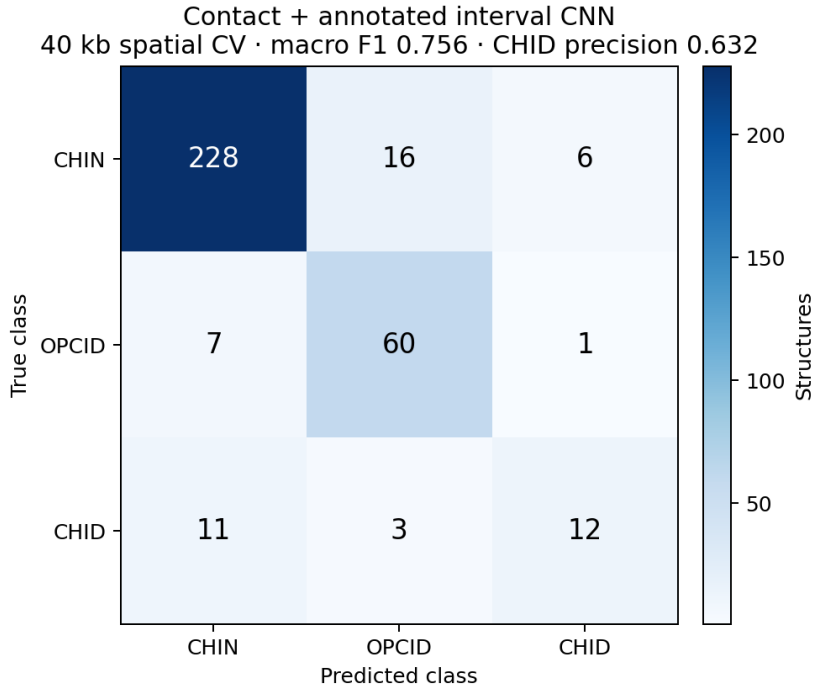


图 1. 接触图加已知区间通道 CNN 的 40 kb 空间五折混淆矩阵；CHID 仍有 14/26 条误判。

任务二：候选发现

以 5,120 bp 窗口、2,560 bp 步长扫描 1,812 个窗口；跨重复筛选后 905 个入选，覆盖 90.1% 的已知注释结构。根据当前操作性规则得到 5 个未注释候选，其 rep1/rep2 距离归一化矩阵上三角相关系数为 0.398–0.669。空间分组留出、rep1 训练而 rep2 测试时，形态线性模型 AUC 0.795、随机森林 AUC 0.821（空间组重采样 95% 区间 0.786–0.854），密度单特征 AUC 0.493。5 个候选在各 100 个远距离和邻近错位对照下，同位点相关性均高于抽样零分布，候选内 BH q 为 0.0099；候选坐标、示例热图及验证表可供复核。

限制同样重要：原全窗口重叠标签诊断 AUC 仅 0.598；将候选阈值改为前 20%、重复相关下限 0.3 后，旧规则的簇支持候选仍为 0。进一步阈值审计发现，原 5 个候选只有 2 个能通过严格的第一道分数/重复门槛。严格重跑得到 9 个“远离已知特征”的窗口，却固定分成 8 个簇并要求每簇至少 5 个成员，导致簇规模门槛几乎不可能满足；这项设计不能用作单个罕见结构是否值得复核的唯一标准。

因此新增一个不取代旧规则的单窗口新颖性层级：严格前 20% 分数、WT 重复相关至少 0.3、无已知注释重叠，并超过已知窗口最近邻距离第 90 百分位。修订后的发现程序以 `--candidate-rule individual` 直接输出 9 个窗口、合并为 7 个位点，与独立后处理审计坐标完全相同；修订规则摘要、原始候选表及逐位点证据表可复核。证据表包含坐标、已知注释距离、WT/44℃/利福平两重复相关和错位对照，另有双重复热图。9 个窗口在 WT、44℃ 和利福平的各 100 次邻近错位对照中，同位点相关性均高于抽样对照；7 个代表位点在两个处理条件中的候选内 BH q 均为 0.0099。处理条件未参与 WT 候选筛选，增加了重复性证据，但 q 的精度受 100 次抽样限制，并非全基因组发现 FDR。7 个位点仍只是优先后续验证的计算候选，不能写成已证实的新结构；旧簇支持数 0 与新单窗口层级 7 应同时保留。

H-NS 缺失的独立条件复核：从 GEO GSE272159 另取两个 H-NS 缺失 Micro-C 重复，不参与 WT 候选筛选。对 7 个代表位点计算 WT 与突变体归一化接触图的组间平方差，并扣除组内重复噪声；背景从 WT 分数、重复相关、已知标注距离相近的 80 个唯一窗口中匹配。候选平均效应 0.668，匹配零分布平均 0.397，探索性组均值随机化 p 0.017；但中位数 p 0.084，且去掉 4,241,920 bp 位点后组均值 p 0.308。7 个单独位点均未通过 BH q<0.05。因此突变体证据主要集中在一个值得优先复核的位点，不能据此宣称 7 个都已验证。更重要的是，WT 与 H-NS 缺失 分别用 NextSeq 2000 与 DNBSEQ-G400 测序，条件和平台/批次混杂；深度匹配不能排除这一点。完整候选/匹配对照结果、敏感性摘要和最高效应位点差异图随分支提供。

WT 条件下待验证的形态候选对 N1：旧固定 KMeans 8 簇、每簇至少 5 个窗口的规则仍是 0。将 7 个严格新颖位点去重后探索性地按形态配对，提名 1 对互不重叠位点 N1：染色体 NC_000913.3 的 3,307,520 bp 和 4,241,920 bp（相隔 934,400 bp）。两者平均归一化图的非近对角上三角相关为 0.480，粗网格特征相关为 0.840；同门槛非候选背景的 7,456 对第 99 百分位分别为 0.279/0.728，两个 WT 重复的相应指标也越过各自背景门槛。这是形态相似的计算提名，不是已经找到新的结构类型。原程序还输出 5,000 次背景抽样的经验 p 0.0002，但下述复核已表明它不能作正式显著性证据。簇成员表、全部候选配对、旧阈值摘要及双重复热图保留以便追溯。

配对背景复核改变了结论强度：在 WT 同分数 / 重复性门槛的全部 130 个窗口中，有 8,332 对互不重叠配对、14 对越过六项形态指标各自的第 99 百分位；N1 按最弱指标百分位仅排第 3。此前 123 个背景窗口虽然能组成 7,456 对，却只有 2 个窗口达到 N1 的新颖性距离，且均与候选重叠，故独立的新颖性匹配背景配对为 0。WT 两重复还同时参与候选筛选与配对形态检验，原经验 p=0.0002 不可解释为发现显著性或 FDR。H-NS 变化主要集中在 4,241,920 bp，不能宣称两成员共享调控机制。旧规则的 0 簇、单窗口层级 7 位点与 N1 候选配对三个层级均如实保留。全配对与背景复核摘要及逐条件配对表可复核。

新做的跨条件反证：冻结 WT 中的 N1 两位点与 123 个背景窗口后，分别在 44℃、利福平 25 和 H-NS 突变的两重复矩阵中重算同一配对形态。N1 两位点平均图的上三角相关分别仅 0.029/0.024/0.151，均低于各条件背景配对第 99 百分位 0.254/0.241/0.215；粗形态也未同时达标。三个条件的逐重复对照分别见 44℃、利福平、H-NS。这不否定其在 WT 两个生物学重复中可见，却否定了“跨条件稳定的新类型”这一更强说法；处理效应和测序深度差异都可能造成变化，目前不能判定具体机制。N1 只保留为 WT 条件下待独立验证的疑似形态簇。

将 WT 选出的 7 个位点所成全部 21 对一同迁移到三个处理条件，用各条件双重复的六项形态门槛统一复核，44℃、利福平和 H-NS 均为 0 对通过；没有找到跨条件更稳的替代簇。21 对跨条件明细保留负结果。处理条件不是第三个独立 WT 重复，因此也不能把这种失败简单归为候选不存在。

另需注意筛选取舍：严格前 20% 分数与重复相关 0.3 的门槛，把已知结构的跨重复召回从原宽松扫描的 90.1% 降至 53.5%。严格层级用于优先复核，不应替代高召回的初筛入口。

已知结构再发现的空间基线：宽松扫描从 1,812 个滑窗选 905 个时，覆盖原 344 条已知注释中的 90.1%；先合并重叠标注得到 216 个独立区间后，仍覆盖 88.4%。为判断这是否只是半数窗口带来的平凡覆盖，把完全相同的选中/未选中序列沿细菌环状基因组作 1,811 个非零循环位移，保留选窗数和簇状程度：合并位点的位移召回中位数 77.3%、第 95 百分位 81.5%，没有一个位移达到观测值。因此“能优先定位已知结构”有一定空间对照支持，满足任务二的基础复现层级；但 50% 的选窗率并不代表高精确率，更不能转化为新类型发现显著性。逐类与合并位点审计可复核。

为减少两重复同时选点又验证的循环证据，补做仅用 WT 第一个重复选点、锁定后才读取第二个重复的回顾性分析。第一个重复的高分未标注窗口合并为 100 个独立位点，其中 16 个超出已知形态第 90 百分位距离，形成 120 对；最优两点仍为 3,307,520/4,241,920 bp，第二重复上三角/粗形态相关为 0.352/0.797。然而要求不共享位点并匹配选点分数、形态新颖性、第一个重复相似度及基因组间距后，91 个独立对中无一对通过双 IQR 卡尺，放宽至 10 IQR 也仅有 1 对。按第一个重复形态边前 10% 冻结的三位点候选组为 2,042,880/3,307,520/4,241,920 bp；第二重复三条边在未匹配对照中仍居前 10%，但其中两条不比各成员的最佳已知形态匹配更像彼此。因此它只是原图中形态可复现的计算候选组，还不是经校准的“新结构类型”。第二重复在此前工作中已被审阅，此流程只能称回顾性数据隔离，不能称前瞻盲测。发现摘要、验证及匹配失败明细和三位点双重复图保存完整负对照。

大尺度背景敏感性进一步下修：对冻结三位点组在两重复逐张使用相同的四种固定视图（距对角线至少 8/16 bin、减去 σ=4 平滑背景、去除行列强度效应）。原远距图中三条边在第二重复均为正；去平滑背景后仅 1/3 边仍为正，原最优配对的相关由远距视图 0.293/0.170 降到 −0.056，仅为覆盖和基因组间距可比的已知结构配对对照第 7 百分位；行列去效应后该边为 0.019，三条边均不超过成员各自最佳已知结构相似度。已知对照每边 200 对且覆盖/间距落在对照第 10–90 百分位；未标注对照虽然也有 200 对，但覆盖未匹配，不能用于严格百分位解释。这说明候选一致性对大尺度背景处理敏感，不能认定独立新结构类型；也不能反过来断言宽带信号必然是技术伪影。逐边和匹配质量摘要、敏感性图及匹配分布可审阅。

异固定条件 WT 文库的额外压力测试：GSM8950767 是 WT 37°C 培养、37°C 固定的单文库；原研究标准协议为室温固定，故不能把它当作同条件第三个生物学重复。冻结三位点直接迁移后，距对角线 ≥8 bin 时三条边仍为正，但 ≥16 bin 仅 1/3 为正，去平滑背景后 2/3 为正；四种视图均 0/3 边超过两端各自最佳已知结构匹配。四视图摘要与逐边结果保留原值。覆盖 QC 显示三个 5.12 kb 原生窗口远距（≥640 bp）非零比例中位数仅 0.024，标准 rep1/rep2 为 0.154/0.168，上三角原始计数中位数为 69,918 对 193,181/196,553。按远距计数比例将标准两重复原生接触各均匀抽稀 100 次后，≥8 bin 三条边在两组中仍各有 100/100 次为正，而 ≥16 bin 三边全正只占 64%/61%，高通视图只占 23%/10%；这一均匀失读模拟未完全复现最宽带下降，却显示精细视图对覆盖敏感。这不是新类型显著性检验，也不能模拟固定温度、距离衰减或其他制样偏差。因此该文库的形态阴性不能证明生物学结构不存在，也没有提供新类型的独立确证。冻结位点覆盖 QC与深度匹配功效检查可复核。

跨重复新颖性与独立数据边界：用 rep1 的 344 个已知结构冻结标准化、PCA 和最近已知形态距离第 90 百分位阈值 8.576，把 rep1 分数门槛选出的全部 100 个未注释独立位点（含锁定三点）投影到 rep2；三点仍 3/3 超阈值，但全体也有 13/100 超阈值。三点本身是从 rep1 的 120 个配对假设中形成的候选组，不是单个先验检验。rep2 已知参考重新校准/拟合仅作敏感性，不参与冻结判定。逐位点审计及全 100 位点背景支持“形态异常跨重复可见”，仍不能绕过高通形态与匹配对照的失败。官方另有相近培养条件的 WT t2 样本，但没有单独公开 COOL；原研究说明主分析使用合并的重复数据，现有 COOL 的接触总数也远超 t1 原始读数，无法认定 t2 独立于现用矩阵。两份 t2 原始 FASTQ 约 187 GB，且需完整重比对，不能冒充可直接使用的第三个盲测。冻结模型与分母摘要列出选择背景。

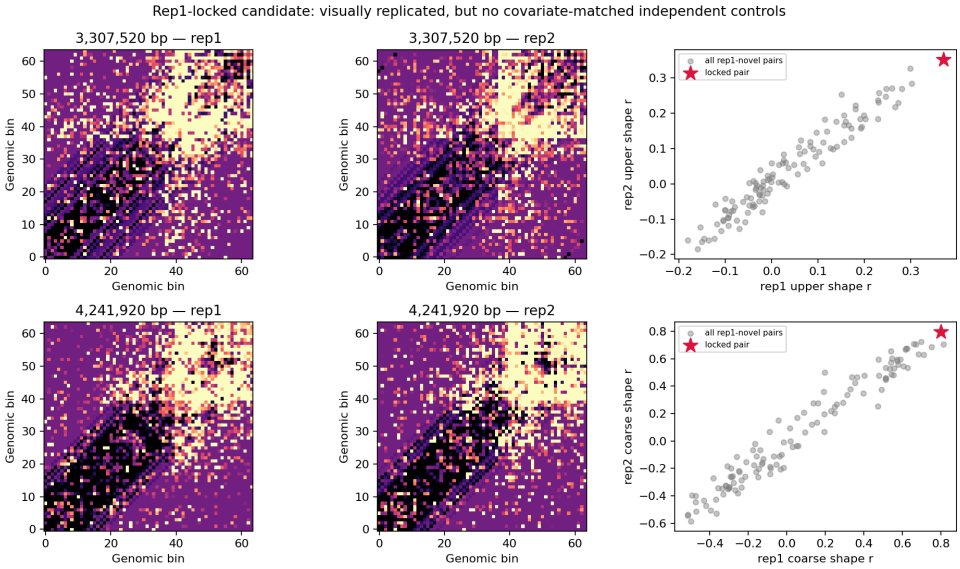


图 2. rep1 冻结配对在 rep2 中形态可见，但缺少协变量匹配的独立背景对照，不能确证新类型。

任务三：多条件轨道

覆盖 4,641,652 bp 染色体的 465 张连续 10 kb 四面板轨道图已生成，叠加 WT 37°C、44°C 与 rifampicin 25 的深度校正接触强度，以及基因、CHIN/OPCID 区间。包含结构标注的代表性区间图随仓库提交，全部逐区间图可按 README 复跑；不将约数百张大图和原始矩阵一并提交 Git。

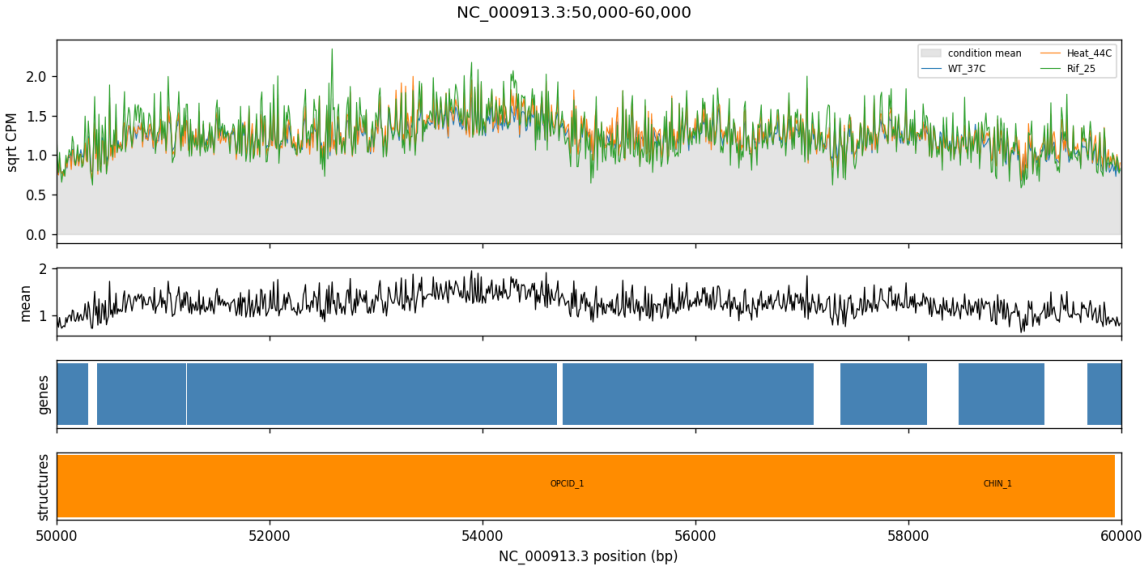


图 3. WT、44°C、利福平及基因/结构标注的代表性 10 kb 多轨道图。

任务四：条件变化

44°C 与 WT 的总体类别平均差值接近零，但局部存在双重复同向变化。旧实现按文件编号配对两个生物学重复，并按遍历顺序二项抽稀；配对没有生物学依据，抽稀结果也会随文件顺序变化。现在每个样本和位点使用固定随机流，要求全部四个处理–对照重复对同方向，且平均效应超过自身重复波动和全体内部重复差异第 95 百分位。预先固定的主种子 20260921 入选 21 条注释、合并为 16 个位点，其中 CHIN 18、CHID 2、OPCID 1；其 逐结构清单 和全部 21 条的 WT/44°C 热图随结果提供。旧版 30 条、24 位点仅保留为历史对照，不再是主结论。

更关键的是抽稀敏感性：另外两个预设种子分别入选 39/30 条，三个种子的交集只有 17 条、合并为 12 个位点，交并比 0.378。稳定交集与完整敏感性摘要是当前最谨慎的候选表。CHIN_94 与重叠的 CHID_9 位于同一位点，不能算两个独立发现。这些仍是探索性筛选，不是正式 FDR 显著性或结构消失的证明。

利福平原始库深度仅约 WT 的 18%；未匹配深度的旧比较与匹配后甚至出现方向翻转，因此旧比较已撤出主结论。修正后三个抽稀种子分别入选 109/107/114 条，交集 98 条、合并为 86 位点，交并比 0.817。利福平稳定交集只供按此局部强度定义审阅，不作机制解释。WT 两重复自身比较的类平均差值接近零。

补做 H-NS 缺失突变体 的两个重复，使用与 WT、44°C 和利福平相同的原始计数抽稀及四重对照规则。三个预设种子分别筛出 101/112/101 条注释，共有 82 条、合并为 64 个互不重叠位点，交并比 0.626，方向翻转为 0。共有注释中 CHIN 70、CHID 7、OPCID 5；按局部非近对角强度定义，CHIN 中 53 条增强、17 条减弱，不能把个别减弱热图概括为全类别变弱。主种子清单、三种子稳定交集、敏感性摘要和 CHIN_45 的 WT/H-NS 代表热图可复核。与 44°C、利福平稳定表分别有 10、21 条注释重合；共享 WT 对照、标注重叠、不同处理深度，以及 WT NextSeq 2000 与 H-NS DNBSEQ-G400 的平台/批次完全混杂，均妨碍“H-NS 特异机制”归因。这仍是探索性效应筛选，不是 FDR 控制后的显著发现，更非 H-NS 直接结合证据。

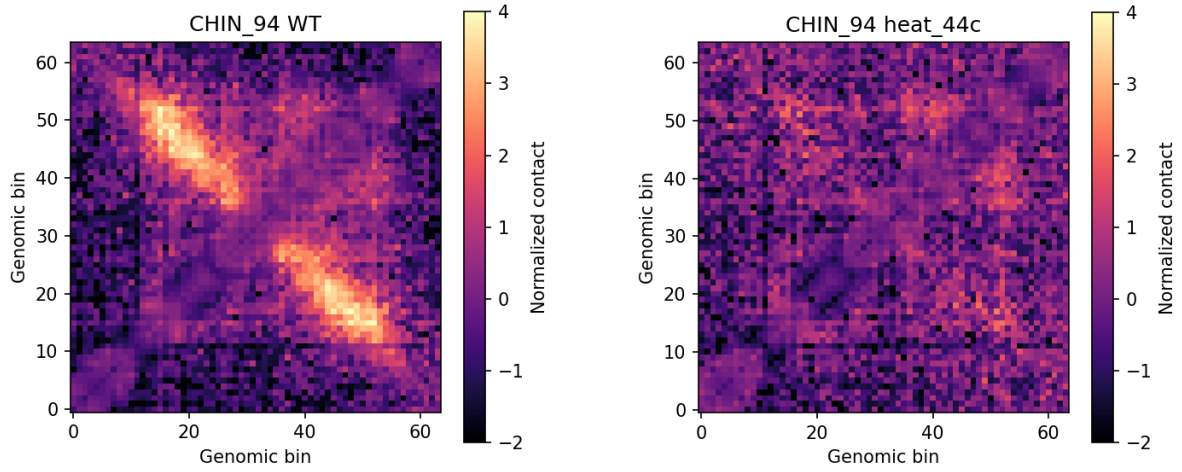


图 4. 主种子筛出的 CHIN_94 位点 WT 与 44°C 热图；跨种子稳定性须以交集表审阅。

任务五：超分辨

4 倍降分辨率（40 bp→10 bp）在 208 个基因组留出窗口上，双线性/CNN 的 PSNR 为 18.901/20.843 dB，SSIM 为 0.118/0.141。成对 PSNR 平均提升 1.942 dB（按连续区段重采样 95% 区间 1.854–2.024），SSIM 提升 0.023（0.020–0.025）。68 个留出区段中的已知结构中心窗口，CNN 的 PSNR 胜率 100%、SSIM 胜率 95.6%，但这不意味着微观接触细节完全恢复。模型、重建矩阵与逐窗口指标均可审阅。

关键修正是从原始计数生成低分辨率输入，再对输入和目标分别归一化；旧版先归一化目标再降分辨率，会泄漏高分辨率背景统计量，其 2 倍/4 倍对照指标已撤下。当前低分辨率输入仍由 Micro-C 自身模拟，不能外推为真实 Hi-C→Micro-C 的跨技术性能。

形态专项复核：从已保存的 208 个留出预测窗口重算非近对角上三角接触排序相关；5 个无非对角信号的窗口不参与此指标。其余 203 个窗口的 Spearman 均值从双线性 0.278 提高到 CNN 0.296，成对增幅 0.018（连续基因组块重采样 95% 区间 0.014–0.021）。这说明局部接触位置排序有小幅改善，但已知结构中心的图像指标仍不能证明自动找回其位置，也不支持“微观结构完整恢复”或独立 Hi-C 泛化。逐窗口形态指标和摘要可复核。

对 68 个留出已知结构中心另做直接检查：局部 640 bp 窗口的非近对角上三角接触排序相关由插值 0.286 升到 CNN 0.307，但高斯平滑后最强接触热点的位置误差由 14.17 增到 15.12 个 10 bp bin，仅 20.6% 的结构中心在定

位误差上改善。该结果表明当前模型主要改善像素强度与局部排序，没有完成可靠的热点定位恢复，更不能推断多 kb 结构整体位置恢复。逐结构结果和摘要已加入。

峰值加权消融：训练损失另给目标图的强正接触更高权重（固定权重 0.5）。它使 68 个已知中心的平均热点误差降到 13.87 bin，略好于插值的 14.17；然而仅 38.2% 的中心比插值定位更准，测试 PSNR 从主模型 20.843 降至 20.670 dB，SSIM 从 0.141 降至 0.111（比插值 0.118 还差），局部形态相关也由 0.307 降至 0.300。故该变体不替换主模型，不能宣称定位问题已稳定解决。变体指标、逐中心结果和权重保留。

验证区选权融合试验：固定主模型与峰值加权模型，在 28 个验证区已知中心上，仅对同时提升 SSIM 和降低平均热点误差的权重计算两项相对增益的乘积；复跑后的选择结果是主模型权重 1.0，即不混合峰值加权模型。208 个测试窗口的 PSNR/SSIM 为 20.843/0.141，但 68 个测试区已知中心的热点误差为 15.12 bin，高于插值 14.17，仅 20.6% 的中心定位更准。故验证区权重选择未解决定位问题。验证网格和测试结果完整保留。由于此前模型开发已多次查看这一测试区段，这只是透明消融，不能称全新独立验证。

局部融合的后续探索：保持两套已训练网络不变，只根据低分辨图及峰值网络自身预测确定局部热点区域，预先列出 17 个全局 / 局部融合选项，并只用 103 个验证窗口和 28 个验证区已知中心选出局部高斯融合（峰值权重 0.5、半径参数 3 bin）。在相同 rep1 留出区 208 个窗口，融合 PSNR/SSIM 为 20.840/0.141（插值 18.901/0.118，主 CNN 20.843/0.141）；68 个已知中心平均热点误差 13.90 bin（插值 14.17，主 CNN 15.12）。固定此方案迁移到未用于选权的 WT rep2，同一区段 PSNR/SSIM 20.998/0.143（插值 18.953/0.116），热点误差 17.99 bin（插值 18.60，主 CNN 18.02）。但对插值的热点增益按位点自助法 95% 区间在 rep1 为 −2.84 至 3.27 bin、rep2 为 −1.97 至 3.32 bin，均跨 0；CHIN 类平均误差在两重复中反而变差。此变体提供了像素指标与平均定位的折中，不证明可靠的热点恢复，且该测试区此前已被查看。验证选择与双重复指标、17 项验证网格、rep1 逐结构误差和rep2 逐结构误差可复核。

更严格的定位复核：另预列六个保守峰锚方案，验证区仍选回原局部高斯融合，没有以测试区重新选型。对插值的平均最强热点定位增益在 rep1/rep2 分别为 0.266/0.609 bin，50 kb 基因组块成对重采样区间 [−2.135, 2.626]/[−2.948, 4.623]；CHIN 单列增益为 −1.192/−0.521 bin，区间也均跨 0。前五局部峰中最近峰的位置误差在 rep1 减少 1.256 bin，区间 [0.199, 2.383]，但 rep2 的 0.947 bin 区间 [−0.134, 2.562] 再度跨 0。反之，两重复在 208 tile 上对插值的 PSNR 提升 1.939/2.045 dB 且区间均为正。故“像素重建稳健，精确结构热点恢复未稳健”是更合适的实验结论。配对置信区间与比较基线、验证六项网格及逐结构结果均保留；这里的测试区此前也已被查看。

结构感知微调的停止线：固定主 CNN 起点、峰位软目标权重 0.05 和 2/5 轮两个检查点，训练结构中心仅取与验证边界相距至少一个 640 bp 窗口的 248 条标注，其中 243 条有可用非对角信号。预先写定选择规则：验证 tile PSNR/SSIM 不可明显低于主模型，且整体与 CHIN 的最强热点误差都要降低；仅有 2 条验证 CHID，不用于选型。第 2/5 轮验证 PSNR 从 20.592 略升至 20.604/20.611 dB，但整体热点误差从 14.139 恶化为 14.462/14.386 bin，CHIN 从 15.879 恶化为 16.191/16.121 bin，故冻结选择仍是原主模型。选择记录、模型/标注/划分哈希和一次性测试见验证决策及固定测试。这轮负结果说明仅加简单峰位损失并未解决结构定位，而非可继续用已看过的测试区刷权重。

主模型复跑审计：按公开的 12 轮、固定种子训练命令重新生成全部 208 个相同测试窗口，旧/新 PSNR 均约 20.843 dB，SSIM 0.14059/0.14068；但权重文件哈希不相同，预测像素平均绝对差 0.0069，已知中心热点误差旧/新为 15.58/15.12 bin，验证区选权旧/新为 0.9/1.0。本分支采用新复跑模型及其后续评估为主结果，旧数值保存在复跑对照。核心“像素改善、定位未可靠改善”的结论未变，不能称逐字节复现。

独立峰候选排序器的有限提升：另以 725 个训练 tile 的 7,133 个图像峰候选拟合排序器，只用 103 个验证 tile 与 28 个已知中心按预列整体/CHIN/top5 保护门槛选回 logistic；三个基因组分区的窗口两两不重叠，选择记录在测试前冻结。它对双线性、主 CNN 与峰值 CNN 的候选峰排序，不改变主 CNN 超分辨图像。两个 WT 重复相同留出区的 68 个已知中心中，前五个候选至少一个落在真值峰 5 bin 内的比例从插值的 0.559 分别升至 0.647/0.691，50

kb 区段成对区间的增益为 [0.029, 0.152]/[0.053, 0.229]；相对主 CNN 自身候选，rep1 的增益区间跨零，rep2 的 [0.015, 0.105] 为正。最强单峰误差虽从 14.169/18.595 降至 12.907/17.322 bin，两重复区间均跨零；CHIN 改善不稳健，OPCID 在 rep2 变差。像素图仍是原主 CNN，不能把检测器候选覆盖写成超分辨图像热点恢复；测试区历史上已被查看，结果属于回顾性留出评估。验证选择、双重复和分块区间及逐结构明细保存完整对照。

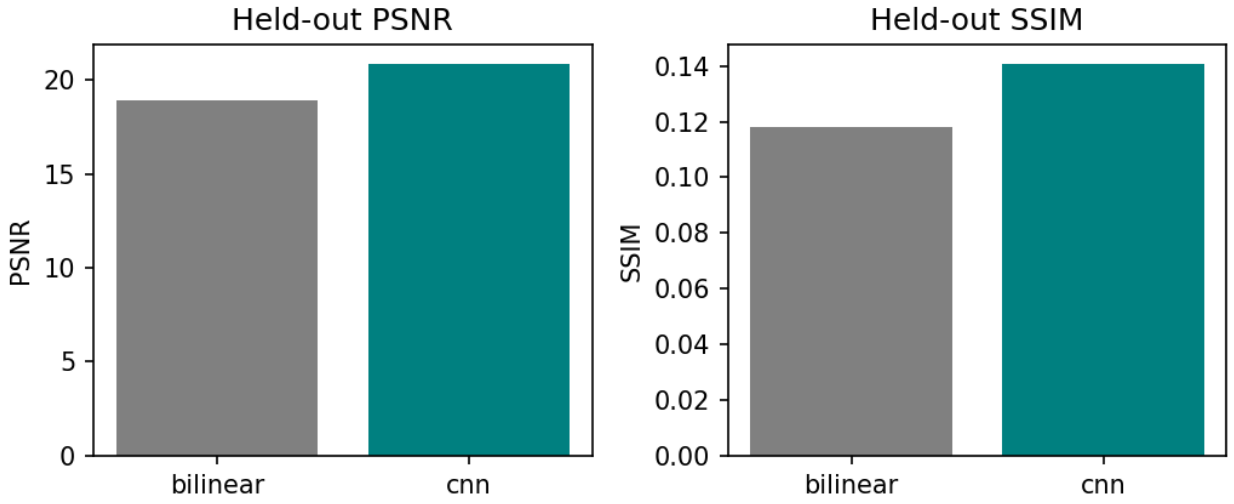


图 5. 4 倍降分辨率任务的重建指标；像素质量改善不代表热点定位改善。

任务六：三维重建

以 5 kb 分箱得到 929 个基因组 bin。审计发现，原神经模型只用最强 20% 接触对训练，虽然 rep1 总体接触-反距离 Spearman 为 0.371（MDS 0.313），但在其未重点训练的较弱正接触层仅 −0.029（MDS 0.291）。因此保留原模型作失败对照，不再把总体指标单独当作充分证据。

改为使用所有正接触对训练，仍不使用 MDS 预训练或坐标正则后，rep1 总体/强接触/较弱正接触相关分别为 0.729/0.394/0.454。更重要的是，坐标只由 rep1 拟合，在未参与训练的 WT rep2 接触图上分别为 0.712/0.398/0.427；同一 rep1-MDS 基线在 rep2 上总体/较弱正接触为 0.319/0.294。改进在两个生物学重复上都可见，但强接触层低于旧模型，属于覆盖范围与极强接触拟合的取舍。新模型权重、坐标、三维轨迹图、反算接触/距离图和逐重复分层对照可复核。弱 MDS 正则的旧消融结果 0.575 仍保留，但不能算独立基线。相关只在正接触对上评价，rep2 对照也不是显微成像真值，坐标仍有旋转、镜像、尺度不唯一性，不能证明真实物理构象。

零接触补充检查：以 3D 距离区分 rep2 中的正接触与归一化后零接触对，新模型 AUC 0.749、旧模型 0.382、同一 rep1-MDS 基线 0.753。新模型修正了旧模型把许多零接触对错误放近的问题，但这一项仅接近而非超过 MDS；零值也不是物理上绝无接触的真值。

基因组距离控制与宏区域标注：按相同的 5 kb bin 间隔精确匹配正残差和被截断为零的残差对，rep2 上新 MLP 的 AUC 0.748，MDS 0.753，只编码环状基因组位置的基线 0.500。因此 0.749 不能简单归因于线性基因组距离，但并未超过 MDS；输入标签是距离归一化残差，不是原始“有/无接触”的物理真值。另根据 MG1655 宏区域定位研究，将近似 Ori、Ter、Left、Right、NSL、NSR 基因组坐标叠加于三维轨迹。颜色标示外部位点标签，不能证明模型重建了这些宏区域的真实空间分隔。

宏区域几何复核：将约 5 kb 的 929 个 bin 按外部近似宏区域标签分组，只在完全相同的环状基因组间距下比较同区与异区的三维距离，平衡抽样后新 MLP 的同区近邻 AUC 为 0.642，rep1-MDS 为 0.602，纯基因组圆环为 0.501（每类 38,682 对）。将宏区域边界附近 ±50 kb 排除后，新 MLP/MDS AUC 为 0.677/0.626；把六个区域标签整体沿环形染色体作全部 928 种非零平移，MLP 原位置的距离效应在全 bin / 边界排除分析的经验上尾比例为 0.029/0.033。这支持学得几何与已发表基因组区域标签存在位置关联，但 MDS 也有该关联，而且这是探索性标签检验，不是独立显微成像或真实三维分区的证据。完整对照与复算脚本可复核。

随机初始化稳定性：固定 rep1 接触目标、无 MDS 先验的 200 轮训练与全部正接触规则，一次列出五个随机种子，不依据 rep2 或宏区域标签选优。五个解在 rep2 正接触上的 Spearman 为 0.706–0.716，高于同一 MDS 基线 0.319；各解两两 3D 距离矩阵的 Spearman 为 0.954–0.991，说明所报接触一致性与几何相对顺序并非单个幸运初始化。但按精确基因组间距匹配的 rep2 正残差/零残差 AUC 仅 0.739–0.750，均未超过 MDS 0.753；宏区域同区近邻 AUC 为 0.627–0.644，仍只是近似基因组标签关联，不是显微成像真值。全部种子、原发布权重对照和坐标见稳定性摘要，没有以后验最优种子替换主模型。

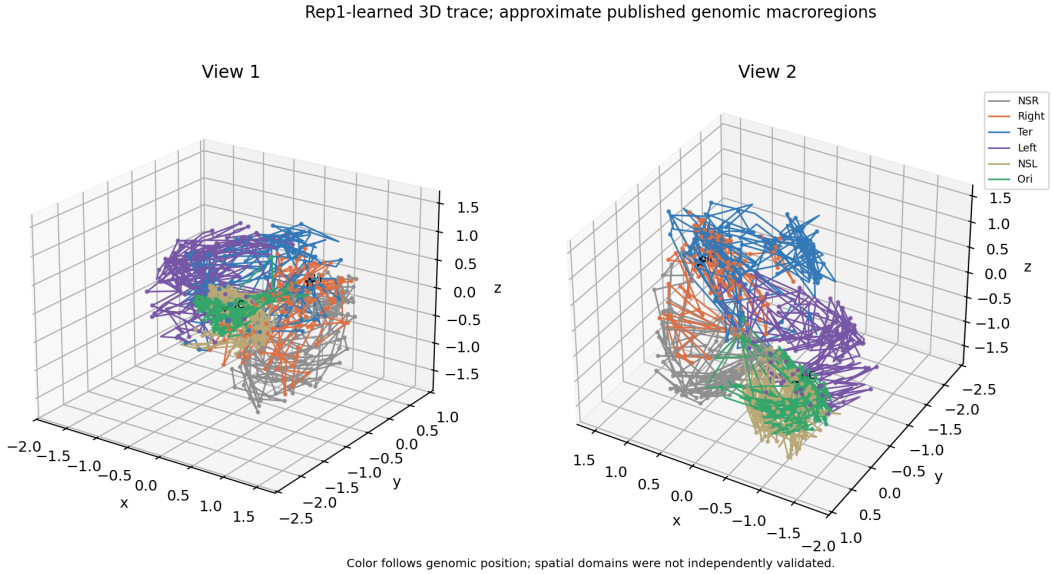


图 6. 学得的三维坐标与外部基因组宏区标签；颜色不证明真实空间分区。

复现与局限

python -m pytest -q tests 覆盖合成 .cool 的读取、归一化、候选管线、轨道、条件比较、超分辨与三维重建。真实数据指标、权重、坐标、代表性图和来源哈希在 results/。所有原始大矩阵位于被 Git 忽略的 data/raw/，下载脚本指向 GEO 官方记录。主要尚未解决的问题是 CHID 分类误报较多、候选数对阈值敏感、利福平深度差异大，以及超分辨和三维重建均缺少独立跨技术真值。