基于深度学习的 Micro-C 接触矩阵分析

三项必做 + 三项选做 · 完整实验报告

数据：大肠杆菌 MG1655 · GEO GSE272159 | 版本：2026-09-28

结果总览

任务一	空间隔离 CNN 准确率 0.870，但 CHID F1=0；边界感知混合模型五折 CHID 精确率/召回率 0.600/0.577。
任务二	7 个未注释位点，组成 1 个待验证形态簇 N1；严格旧簇规则为 0，跨处理条件不稳定。
任务三	覆盖全基因组的 465 张 10 kb 多轨道图，附原始图像清单与哈希。
任务四	44°C 主种子筛出 21 条注释，三种子交集 17 条；属于探索性差异候选。
任务五	4 倍模拟超分辨率 PSNR 较双线性插值提升 1.942 dB，热点定位仍未达标。
任务六	WT rep2 接触-距离 Spearman 0.712；精确距离匹配 AUC 0.748，未超过 MDS 0.753。

证据边界：本报告如实保留未通过的阈值、少数类识别、跨条件迁移、热点定位和三维基线对照；计算候选不等同于已证实的新生物学结构。完整数据来源、代码、逐样本指标及权重可由仓库链接复核。

设计思路

本项目以大肠杆菌 MG1655 的 10 bp Micro-C 接触矩阵为输入，按课程方案完成三项必做及三项选做任务。核心开放问题是：在 OPCID、CHIN、CHID 的 344 条注释之外，能否找到可复现且形态不同的局部接触模式？“新结构”在此仅指满足明确计算规则的未注释候选，不等同于新的生物学实体。原始矩阵来自 NCBI GEO GSE272159；注释来自课程工作簿 Supplementary Tables 4/5/6。原始数据的文件哈希见 provenance.json。

项目首先用两个独立 WT 37°C 重复完成已知结构训练与全基因组发现，再用跨重复、错位窗口、背景样本和阈值敏感性对照验证候选。可选任务分别采用两条件重复配对、模拟降分辨率超分辨，以及全基因组三维坐标优化。方法细节及复跑命令见 METHODS.md 和 README.md。

方法选择与对照实验

任务	方法与设计选择	主要对照
1 已知结构识别	类别加权 CNN；按不重叠基因组邻近组划分训练、验证、测试；另做重叠感知 CHID 五折交叉预测	空间隔离混淆矩阵；CHID 中心单标签与邻近存在检测分开评价
2 候选发现	全基因组切窗、距离归一化、自编码器异常分数、形态与密度融合、PCA/KMeans	已知结构召回；空间留出且跨重复的已知/背景分类；密度单特征；远距离与邻近错位零分布；严格阈值
3 多轨道图	10 kb 连续区间，四面板叠加 WT、44°C、利福平与基因/结构注释	全长覆盖数量与代表性图像核查
4 条件变化	两个 WT 与两个处理重复；原始计数聚合后二项抽稀到共同测序深度；比较局部归一化强度	WT 重复对照、重复方向一致性、内部重复波动第 95 百分位；44°C 与低深度利福平分开报告
5 超分辨	4 倍原始计数合并形成低分辨率输入；输入与目标各自归一化；残差块 CNN；基因组区段留出	双线性插值、成对 PSNR/SSIM、块自助法区间、已知结构中心恢复
6 三维重建	5 kb 全基因组分箱；不使用 MDS 先验的神经坐标优化	独立 MDS 基线、弱 MDS 正则消融、反算接触图

评价指标与结果

任务一：已知结构识别

原默认 CNN 对照：严格空间隔离的 69 个留出结构、两个重复共 138 个样本上，准确率 0.870、宏 F1 0.599。混淆矩阵 显示 CHIN/OPCID 的 F1 为 0.916/0.880，但 CHID 的 F1 0（12 个测试样本无一识别）。这意味着总体准确率乐观、少数类表现却不合格，不能声称三类都稳定识别。按验证集试验把 CHID 损失权重加倍后，验证集宏 F1 仅从 0.620 微升到 0.622，测试集准确率/宏 F1 反降至 0.826/0.557；不采用该变体。空间隔离指标、显著性图及分区审计已保存。

显著性证据审计：原 CHID 图在没有正确分类样本时回退到“真实类型为 CHID 但预测错误”的样本，不能作为 CHID 被识别的证据。现在图题显式标明 12/12 个 CHID 测试样本均误判为 CHIN。进一步以同对角距离的非注释像素作背景，比较真实类别 logit 的输入梯度在注释方块内的富集：正确分类结构的中位数为 CHIN 0.975（41 个可评价结构）、OPCID 1.066（8 个）；均没有显示强而稳定的结构内归因。CHID 没有正确分类样本可做这一检验，且多数

CHID 注释比 5.12 kb 输入窗更宽。这一审计不能支持“模型主要关注结构而非背景”的强说法；逐样本表与摘要给出全部分母和限制。

在相同的 10.24 kb 隔离分区上，5.12 kb/10.24 kb 观察窗的验证宏 F1 为 0.631/0.651；对应测试准确率 0.684/0.816，但测试宏 F1 0.606/0.547，CHID 召回率 0.400/0。宽窗口牺牲了少数类，且这个分区与上面的 5.12 kb 主实验不同，不能把两个测试集当作同一批样本比较。这里只是探索性分析，不以测试集回头挑模型；窄窗和宽窗的完整指标均保留。

另试保留 4×4 空间布局的 CNN 末层，以减少全局平均池化对相对位置的抹除。同一 5.12 kb 空间分区上，验证宏 F1 从 0.620 增至 0.674，但测试准确率/宏 F1 从 0.870/0.599 降至 0.725/0.550；CHID 只识别出 2/12，精确率 0.100。该探索性变体说明位置特征可能有用，但当前样本量下泛化不可靠，不替换主模型。测试集已经多次用于透明诊断，今后的模型选择需要重新设立独立区域或嵌套交叉验证，不应再把现有测试集称为从未查看的留出集。

旧版按结构 ID 分组的准确率 0.746、宏 F1 0.642、CHID 精确率/召回率 0.185/0.500，只保留作对照。旧分区的额外类别阈值使测试准确率/宏 F1 降至 0.645/0.564；10.24 kb 宽窗口使验证宏 F1 从 0.589 降至 0.566。这些旧分区实验均不能作为空间独立性能证据；记录见旧版指标、校准试验和宽窗口试验。

分类评估审计：旧版 69 个测试注释中有 45 个与另一分区的注释中心相距不足 5,120 bp，导致输入窗口可能重叠；审计数据可复核。新版以相邻中心间距小于一个完整输入窗口的连通分组划分，所有分区之间的最近中心距离均超过 5,120 bp。26 个 CHID 中有 25 个距离某个 CHIN 中心不足 5,120 bp，其中 19 个不足 1 kb；固定窗口的单标签分类本身存在相邻结构混合问题。空间隔离成绩作为可靠对照，但它并未解决 CHID 样本稀少及邻近 CHIN 注释造成的可分性问题。

重叠感知的补充任务：把标签预先定义为“注释中心 ±1 kb 内是否存在 CHID”，56/344 个中心为阳性，并用互不重叠的基因组连通组做五折交叉预测。该二分类模型的平均精确率 0.404（空间组自助法 95% 区间 0.256–0.569，阳性基率 0.163），固定 0.5 阈值下精确率/召回率 0.329/0.500。若仍用原来的“中心注释本身是 CHID”计分，同一预测的精确率为 0.153，并没有解决原单标签任务。这是一个不同、更加符合邻近结构共存的检测任务，绝不与旧版 0.185 精确率直接比较；五折预测、指标及不确定性可复核。

原单标签任务的进一步改进：26 个 CHID 中有 17 个注释跨度超过 5.12 kb。为排除位置泄漏，按更保守的 20.48 kb 邻近组做五折交叉预测，固定训练 12 轮，不从外层测试折选阈值。使用 GroupNorm 的 5.12 kb 局部 CNN 达到总体准确率 0.826、宏 F1 0.630；CHID 精确率 0.417（5/12）、召回率 0.192（5/26），空间组自助法的精确率 95% 区间 0.125–0.750。它在原标签下比旧版 0.185 更有希望，但评估划分不同、区间很宽，不能把差值当作已证实提升；尤其两折完全没有报出 CHID。对 24 对邻近 CHID–CHIN 加排序约束，精确率由同折对照 0.231 降至 0.190；同一 20.48 kb 分区上加入 20.48 kb 接触图通道，精确率由 0.417 降至 0.235、宏 F1 从 0.630 降至 0.591，均不采用。完整五折指标、逐结构预测、不确定性、失败的成对对照和最终训练权重随分支提供。最终权重用全部 344 条标注训练，只用于推理，性能以五折结果为准。CHID 的低召回和标注重叠仍是未解决的局限。

已知区间分类的可用改进：保留原始 CHIN/OPCID/CHID 三分类标签，用更严格的 40 kb 空间连通组做五折交叉预测。单看标注跨度的逻辑回归得到 CHID 精确率/召回率 0.348/0.615；单看接触图的 GroupNorm CNN 为 0.217/0.192，将跨度直接接入 CNN 为 0.294/0.192，后者仍不如长度基线。改用两个 WT 重复的接触形态特征均值加已知区间跨度、类别加权的直方图梯度提升，达到准确率 0.866、宏 F1 0.721、CHID 精确率 0.588（10/17）、召回率 0.385（10/26）。同折的接触形态单独模型为 0.500/0.115，跨度单独模型为 0.308/0.615；因此提升不是单纯利用区间长度。40 kb 空间组自助法给出 CHID 精确率 95% 区间 0.333–0.800，样本仍少。另三个 40 kb 折种子的精确率/召回率在 0.563–0.647/0.346–0.423，三个 20 kb 折种子为 0.458–0.611/0.423。全部六种形态/跨度模型的同折指标、逐结构交叉预测、不确定性及最终模型均保留；最终模型以全部 344 条标注训练，不以训练分数报告泛化。该方法并非纯深度学习模型，且跨度只在已知区间有定义，不能用于无标注区域扫描；多个方案的后验比较也需要新的独立标注集验证。

若更重视少漏检，在每个外层训练集内再做三折空间交叉预测选择 CHID 阈值，完全不使用外层测试标签选阈值；五个外层折汇总的 CHID 精确率/召回率变为 0.386/0.654（17/44 个预测为真、17/26 个真 CHID 找回），准确率 0.840、宏 F1 0.721。这是一项更高召回、误报更多的取舍，并非同时改善所有指标；逐折阈值和外层预测已保留。最终模型的部署阈值另由全部训练标注内部的空间交叉预测选择，不把其训练集表现充当测试成绩。推理脚本已和训练时的 4×4 原始计数聚合核对，344/344 个已知区间的模型预测一致。

进一步的边界感知模型：针对 CHID 常宽于 5.12 kb 的问题，从独立归一化的 20.48 kb 接触图提取已知区间内部、两侧及跨边界接触，与 5.12/20.48 kb 形态和区间跨度合用。40 kb 隔离五折的准确率 0.895、宏 F1 0.787、CHID 精确率 0.600（15/25）、召回率 0.577（15/26）。同折短尺度模型为 0.866/0.721/0.588/0.385（依次为准确率、宏 F1、CHID 精确率、召回率）；CHID 召回差 +0.192，配对空间组重采样 95% 区间 +0.030 至 +0.400，宏 F1 差的区间 □0.007 至 +0.148，不能宣称整体提升已被独立证实。另三个 40 kb 折种子的 CHID 精确率/召回率为 0.500–0.600/0.462–0.577，三个 20 kb 折种子为 0.483–0.556/0.538–0.577；召回改善较一致，精确率并非每次都改善。直接拼接多尺度特征以及短/长模型等权概率平均的对照不稳定，均不替代边界模型。全部同折对照、逐结构预测、配对不确定性、最终模型可复核。最终模型用全部 344 条标注训练，推理预处理与缓存数据 344/344 一致。它仍依赖已知区间的起止坐标，不能直接扫描未知结构；仅 26 个 CHID 且多次后验模型比较，仍需要独立标注集。

WT 生物学重复迁移审计：固定同一 40 kb 空间五折、只以 rep1 特征训练而在 rep2 的留出位点测试，CHID 精确率/召回率 0.500/0.500、宏 F1 0.762；反向 rep2→rep1 为 0.455/0.385、宏 F1 0.714，两重复联合为 0.600/0.577、宏 F1 0.787。在另一 40 kb 折种子和 20 kb 分区中也出现方向不对称；两重复联合不是每次都优于单向迁移。全部模式与逐结构预测已保留。这说明部分成绩受具体重复影响；它是同一套标注的技术/生物重复稳健性审计，不是独立标签集的外部验证。

纯 CNN 类别不平衡补充试验：在同一 40 kb 空间五折、只输入接触图、固定 12 轮的设定下，把训练折内类别权重从平方根逆频率改为完全逆频率。CHID 召回提高到 0.385（10/26），但精确率降为 0.159（10/63），总体准确率/宏 F1 为 0.721/0.578；过多 CHIN 被误报为 CHID。故不采用该变体，也不能用它宣称纯 CNN 已稳定完成三类识别。逐结构预测与混淆矩阵摘要保留为失败对照。

辅助标注加分项：新增离线人工复核页，将任务二的 7 个独立位点、两重复热图、重复相关、距已知注释距离及任务一 CNN 对已知三类形态的提示放在同一页面。审阅者可逐位点填写“保留候选 / 更像已知类 / 疑似噪声”和备注，导出 JSON；原始矩阵和选择不上传。CNN 对这些未注释窗口属于分布外推断，尤其 CHID 识别薄弱，所示分数不是候选为新结构的概率，页面不会自动给出新颖性结论。模型提示表和生成脚本可复核。

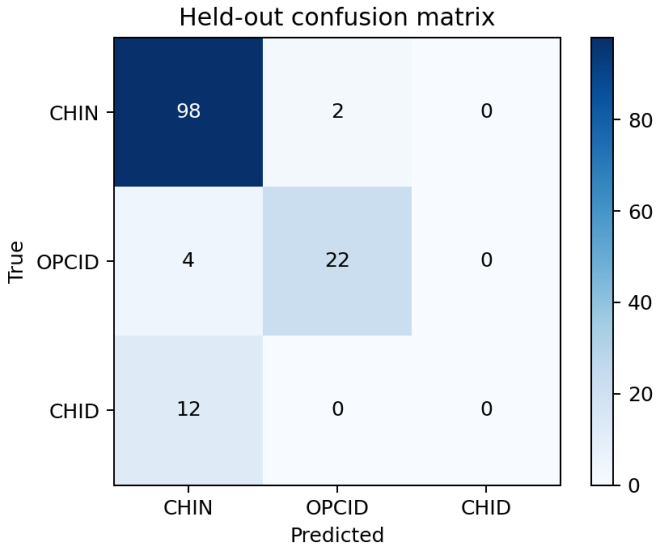


图 1. 严格空间隔离 CNN 混淆矩阵；CHID 测试样本未被正确识别。

任务二：候选发现

以 5,120 bp 窗口、2,560 bp 步长扫描 1,812 个窗口；跨重复筛选后 905 个入选，覆盖 90.1% 的已知注释结构。根据当前操作性规则得到 5 个未注释候选，其 rep1/rep2 距离归一化矩阵上三角相关系数为 0.398–0.669。空间分组留出、rep1 训练而 rep2 测试时，形态线性模型 AUC 0.795、随机森林 AUC 0.821（空间组重采样 95% 区间 0.786–0.854），密度单特征 AUC 0.493。5 个候选在各 100 个远距离和邻近错位对照下，同位点相关性均高于抽样零分布，候选内 BH q 为 0.0099；候选坐标、示例热图及验证表可供复核。

限制同样重要：原全窗口重叠标签诊断 AUC 仅 0.598；将候选阈值改为前 20%、重复相关下限 0.3 后，旧规则的簇支持候选仍为 0。进一步阈值审计发现，原 5 个候选只有 2 个能通过严格的第一道分数/重复门槛。严格重跑得到 9 个“远离已知特征”的窗口，却固定分成 8 个簇并要求每簇至少 5 个成员，导致簇规模门槛几乎不可能满足；这项设计不能用作单个罕见结构是否值得复核的唯一标准。

因此新增一个不取代旧规则的单窗口新颖性层级：严格前 20% 分数、WT 重复相关至少 0.3、无已知注释重叠，并超过已知窗口最近邻距离第 90 百分位。修订后的发现程序以 `--candidate-rule individual` 直接输出 9 个窗口、合并为 7 个位点，与独立后处理审计坐标完全相同；修订规则摘要、原始候选表及逐位点证据表可复核。证据表包含坐标、已知注释距离、WT/44°C/利福平两重复相关和错位对照，另有双重复热图。9 个窗口在 WT、44°C 和利福平的各 100 次邻近错位对照中，同位点相关性均高于抽样对照；7 个代表位点在两个处理条件中的候选内 BH q 均为 0.0099。处理条件未参与 WT 候选筛选，增加了重复性证据，但 q 的精度受 100 次抽样限制，并非全基因组发现 FDR。7 个位点仍只是优先后续验证的计算候选，不能写成已证实的新结构；旧簇支持数 0 与新单窗口层级 7 应同时保留。

H-NS 缺失的独立条件复核：从 GEO GSE272159 另取两个 H-NS 缺失 Micro-C 重复，不参与 WT 候选筛选。对 7 个代表位点计算 WT 与突变体归一化接触图的组间平方差，并扣除组内重复噪声；背景从 WT 分数、重复相关、已知标注距离相近的 80 个唯一窗口中匹配。候选平均效应 0.668，匹配零分布平均 0.397，探索性组均值随机化 p 0.017；但中位数 p 0.084，且去掉 4,241,920 bp 位点后组均值 p 0.308。7 个单独位点均未通过 BH q<0.05。因此突变体证据主要集中在一个值得优先复核的位点，不能据此宣称 7 个都已验证，也不能排除技术批次差异。完整候选/匹配对照结果、敏感性摘要和最高效应位点差异图随分支提供。

疑似新结构类型 N1：旧固定 KMeans 8 簇、每簇至少 5 个窗口的规则仍是 0，不能改写。为回答任务二“发现新的类型”，进一步将 7 个严格新颖位点去重后按形态相似性重新成簇，找到 1 个由 2 个互不重叠位点组成的疑似新簇 N1：染色体 NC_000913.3 的 3,307,520 bp 和 4,241,920 bp（相隔 934,400 bp）。两者平均归一化图的非近对角上三角相关为 0.480，粗网格特征相关为 0.840；同门槛非候选背景的 7,456 对第 99 百分位分别为 0.279/0.728，并且在两个 WT 重复中分别超过各自背景第 99 百分位。与全部 344 个已知注释中心比较时，两成员对彼此的形态相似度也高于各自的最佳已知匹配。对 7 个候选的最大配对相关进行 5,000 次互不重叠背景集合抽样，探索性经验 p 0.0002。证据见簇成员表、全部候选配对、阈值摘要及双重复热图。

这属于可复现的计算发现，不是已证实的全新生物学结构：成簇判据在看到候选之后确定，背景只匹配分数和重复性门槛，没有完全匹配形态新颖性；p 值不是全基因组 FDR。H-NS 变化主要集中在 4,241,920 bp，不能宣称 N1 两成员共享同一调控机制。旧规则的 0 簇、单窗口层级的 7 位点与新形态配对层级的 1 个疑似簇分别保留。

新做的跨条件反证：冻结 WT 中的 N1 两位点与 123 个背景窗口后，分别在 44°C、利福平 25 和 H-NS 突变的两重复矩阵中重算同一配对形态。N1 两位点平均图的上三角相关分别仅 0.029/0.024/0.151，均低于各条件背景配对第 99 百分位 0.254/0.241/0.215；粗形态也未同时达标。三个条件的逐重复对照分别见 44°C、利福平、H-NS。这不否定其在 WT 两个生物学重复中可见，却否定了“跨条件稳定的新类型”这一更强说法；处理效应和测序深度差异都可能造成变化，目前不能判定具体机制。N1 只保留为 WT 条件下待独立验证的疑似形态簇。

另需注意筛选取舍：严格前 20% 分数与重复相关 0.3 的门槛，把已知结构的跨重复召回从原宽松扫描的 90.1% 降至 53.5%。严格层级用于优先复核，不应替代高召回的初筛入口。

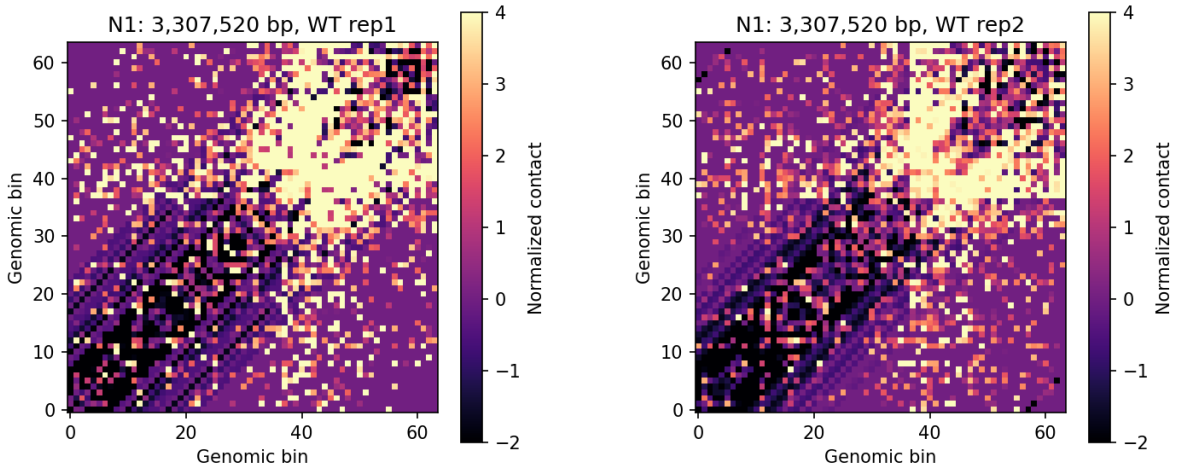


图 2. 待验证 N1 位点之一在两个 WT 生物学重复中的局部接触图；不是新结构的独立验证。

任务三：多条件轨道

覆盖 4,641,652 bp 染色体的 465 张连续 10 kb 四面板轨道图已生成，叠加 WT 37°C、44°C 与 rifampicin 25 的深度校正接触强度，以及基因、CHIN/OPCID 区间。包含结构标注的代表性区间图随仓库提交，全部逐区间图可按 README 复跑；不将约数百张大图和原始矩阵一并提交 Git。

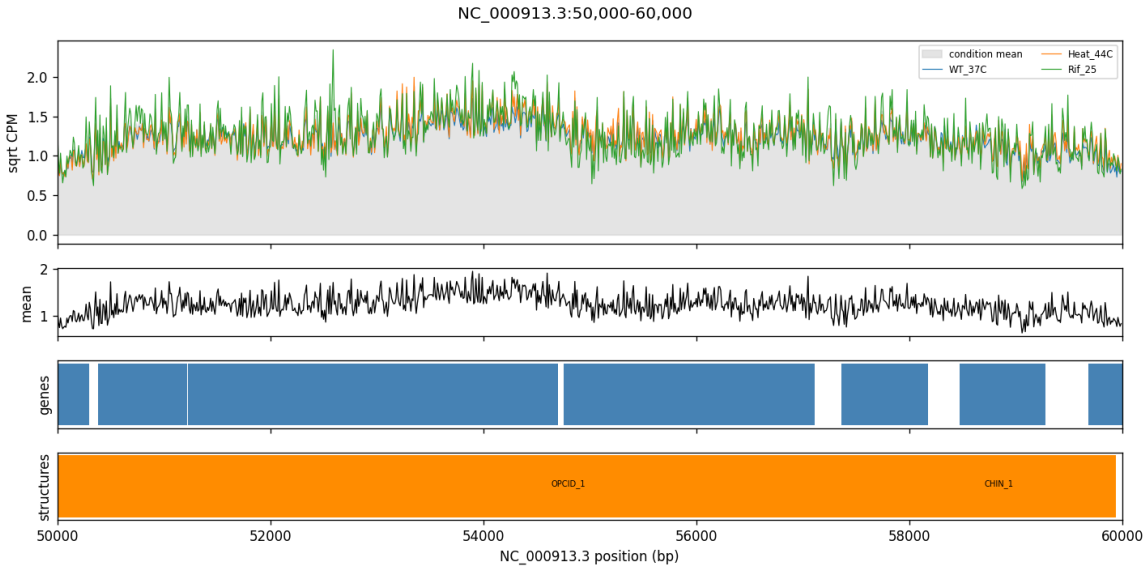


图 3. WT、44°C、利福平及基因/结构标注的代表性 10 kb 多轨道图。

任务四：条件变化

44°C 与 WT 的总体类别平均差值接近零，但局部存在双重复同向变化。旧实现按文件编号配对两个生物学重复，并按遍历顺序二项抽稀；配对没有生物学依据，抽稀结果也会随文件顺序变化。现在每个样本和位点使用固定随机流，要求全部四个处理–对照重复对同方向，且平均效应超过自身重复波动和全体内部重复差异第 95 百分位。预先固定的主种子 20260921 入选 21 条注释、合并为 16 个位点，其中 CHIN 18、CHID 2、OPCID 1；其 逐结构清单 和全部 21 条的 WT/44°C 热图随结果提供。旧版 30 条、24 位点仅保留为历史对照，不再是主结论。

更关键的是抽稀敏感性：另外两个预设种子分别入选 39/30 条，三个种子的交集只有 17 条、合并为 12 个位点，交并比 0.378。稳定交集与完整敏感性摘要是当前最谨慎的候选表。CHIN_94 与重叠的 CHID_9 位于同一位点，不能算两个独立发现。这些仍是探索性筛选，不是正式 FDR 显著性或结构消失的证明。

利福平原始库深度仅约 WT 的 18%；未匹配深度的旧比较与匹配后甚至出现方向翻转，因此旧比较已撤出主结论。修正后三个抽稀种子分别入选 109/107/114 条，交集 98 条、合并为 86 位点，交并比 0.817。利福平稳定交集只供按此局部强度定义审阅，不作机制解释。WT 两重复自身比较的类平均差值接近零。

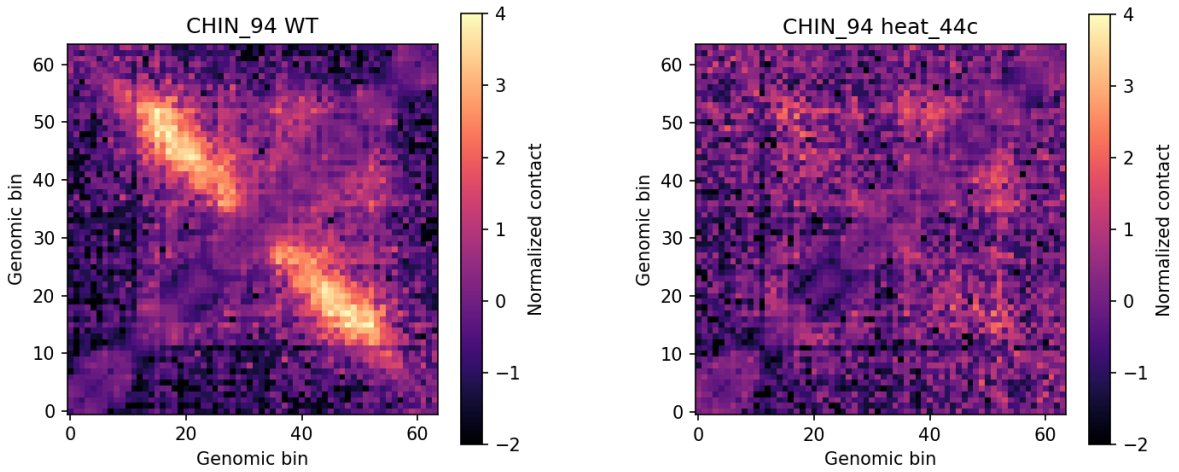


图 4. 主种子筛出的 CHIN_94 位点 WT 与 44℃ 热图；跨种子稳定性须以交集表审阅。

任务五：超分辨

4 倍降分辨率（40 bp→10 bp）在 208 个基因组留出窗口上，双线性/CNN 的 PSNR 为 18.901/20.843 dB，SSIM 为 0.118/0.141。成对 PSNR 平均提升 1.942 dB（按连续区段重采样 95% 区间 1.854–2.024），SSIM 提升 0.023（0.020–0.025）。68 个留出区段中的已知结构中心窗口，CNN 的 PSNR 胜率 100%、SSIM 胜率 95.6%，但这不意味着微观接触细节完全恢复。模型、重建矩阵与逐窗口指标均可审阅。

关键修正是从原始计数生成低分辨率输入，再对输入和目标分别归一化；旧版先归一化目标再降分辨率，会泄漏高分辨率背景统计量，其 2 倍/4 倍对照指标已撤下。当前低分辨率输入仍由 Micro-C 自身模拟，不能外推为真实 Hi-C→Micro-C 的跨技术性能。

形态专项复核：从已保存的 208 个留出预测窗口重算非近对角上三角接触排序相关；5 个无非对角信号的窗口不参与此指标。其余 203 个窗口的 Spearman 均值从双线性 0.278 提高到 CNN 0.296，成对增幅 0.018（连续基因组块重采样 95% 区间 0.014–0.021）。这说明局部接触位置排序有小幅改善，但已知结构中心的图像指标仍不能证明自动找回其位置，也不支持“微观结构完整恢复”或独立 Hi-C 泛化。逐窗口形态指标和摘要可复核。

对 68 个留出已知结构中心另做直接检查：局部 640 bp 窗口的非近对角上三角接触排序相关由插值 0.286 升到 CNN 0.307，但高斯平滑后最强接触热点的位置误差由 14.17 增到 15.12 个 10 bp bin，仅 20.6% 的结构中心在定位误差上改善。该结果表明当前模型主要改善像素强度与局部排序，没有完成可靠的热点定位恢复，更不能推断多 kb 结构整体位置恢复。逐结构结果和摘要已加入。

峰值加权消融：训练损失另给目标图的强正接触更高权重（固定权重 0.5）。它使 68 个已知中心的平均热点误差降到 13.87 bin，略好于插值的 14.17；然而仅 38.2% 的中心比插值定位更准，测试 PSNR 从主模型 20.843 降至 20.670 dB，SSIM 从 0.141 降至 0.111（比插值 0.118 还差），局部形态相关也由 0.307 降至 0.300。故该变体不替换主模型，不能宣称定位问题已稳定解决。变体指标、逐中心结果和权重保留。

验证区选权融合试验：固定主模型与峰值加权模型，在 28 个验证区已知中心上，仅对同时提升 SSIM 和降低平均热点误差的权重计算两项相对增益的乘积；复跑后的选择结果是主模型权重 1.0，即不混合峰值加权模型。208 个测试窗口的 PSNR/SSIM 为 20.843/0.141，但 68 个测试区已知中心的热点误差为 15.12 bin，高于插值 14.17，仅

20.6% 的中心定位更准。故验证区权重选择未解决定位问题。验证网格和测试结果完整保留。由于此前模型开发已多次查看这一测试区段，这只是透明消融，不能称全新独立验证。

主模型复跑审计：按公开的 12 轮、固定种子训练命令重新生成全部 208 个相同测试窗口，旧/新 PSNR 均约 20.843 dB，SSIM 0.14059/0.14068；但权重文件哈希不相同，预测像素平均绝对差 0.0069，已知中心热点误差旧/新为 15.58/15.12 bin，验证区选权旧/新为 0.9/1.0。本分支采用新复跑模型及其后续评估为主结果，旧数值保存在复跑对照。核心“像素改善、定位未可靠改善”的结论未变，不能称逐字节复现。

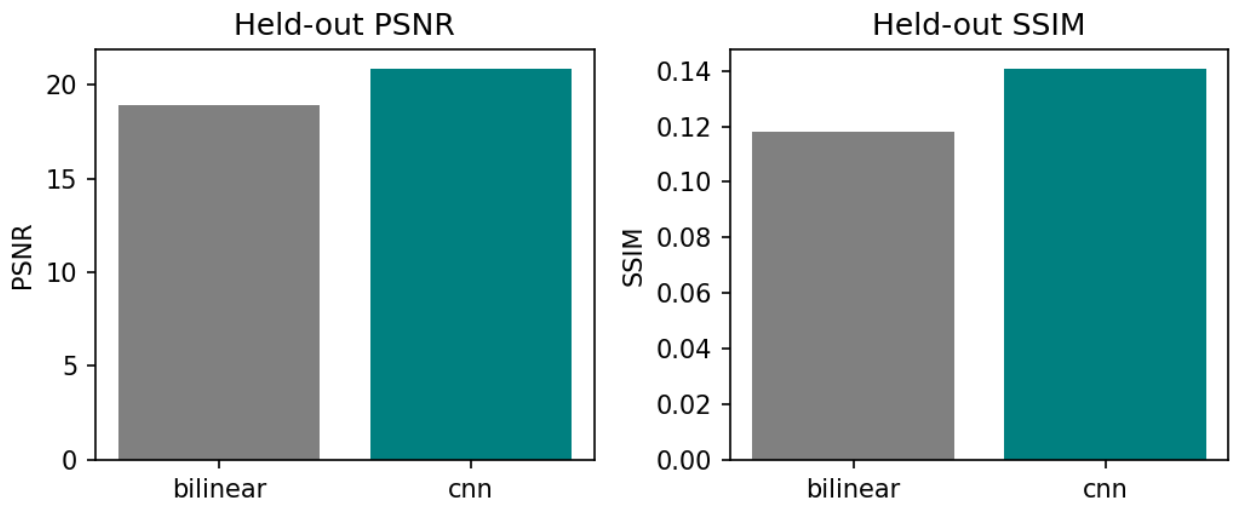


图 5. 4 倍降分辨率任务的重建指标；像素质量改善不代表热点定位改善。

任务六：三维重建

以 5 kb 分箱得到 929 个基因组 bin。审计发现，原神经模型只用最强 20% 接触对训练，虽然 rep1 总体接触-反距离 Spearman 为 0.371（MDS 0.313），但在其未重点训练的较弱正接触层仅 □0.029（MDS 0.291）。因此保留原模型作失败对照，不再把总体指标单独当作充分证据。

改为使用所有正接触对训练，仍不使用 MDS 预训练或坐标正则后，rep1 总体/强接触/较弱正接触相关分别为 0.729/0.394/0.454。更重要的是，坐标只由 rep1 拟合，在未参与训练的 WT rep2 接触图上分别为 0.712/0.398/0.427；同一 rep1-MDS 基线在 rep2 上总体/较弱正接触为 0.319/0.294。改进在两个生物学重复上都可见，但强接触层低于旧模型，属于覆盖范围与极强接触拟合的取舍。新模型权重、坐标、三维轨迹图、反算接触/距离图和逐重复分层对照可复核。弱 MDS 正则的旧消融结果 0.575 仍保留，但不能算独立基线。相关只在正接触对上评价，rep2 对照也不是显微成像真值，坐标仍有旋转、镜像、尺度不唯一性，不能证明真实物理构象。

零接触补充检查：以 3D 距离区分 rep2 中的正接触与归一化后零接触对，新模型 AUC 0.749、旧模型 0.382、同一 rep1-MDS 基线 0.753。新模型修正了旧模型把许多零接触对错误放近的问题，但这一项仅接近而非超过 MDS；零值也不是物理上绝无接触的真值。

基因组距离控制与宏区域标注：按相同的 5 kb bin 间隔精确匹配正残差和被截断为零的残差对，rep2 上新 MLP 的 AUC 0.748，MDS 0.753，只编码环状基因组位置的基线 0.500。因此 0.749 不能简单归因于线性基因组距离，但并未超过 MDS；输入标签是距离归一化残差，不是原始“有/无接触”的物理真值。另根据 MG1655 宏区域定位研究，将近似 Ori、Ter、Left、Right、NSL、NSR 基因组坐标叠加于三维轨迹。颜色标示外部位点标签，不能证明模型重建了这些宏区域的真实空间分隔。

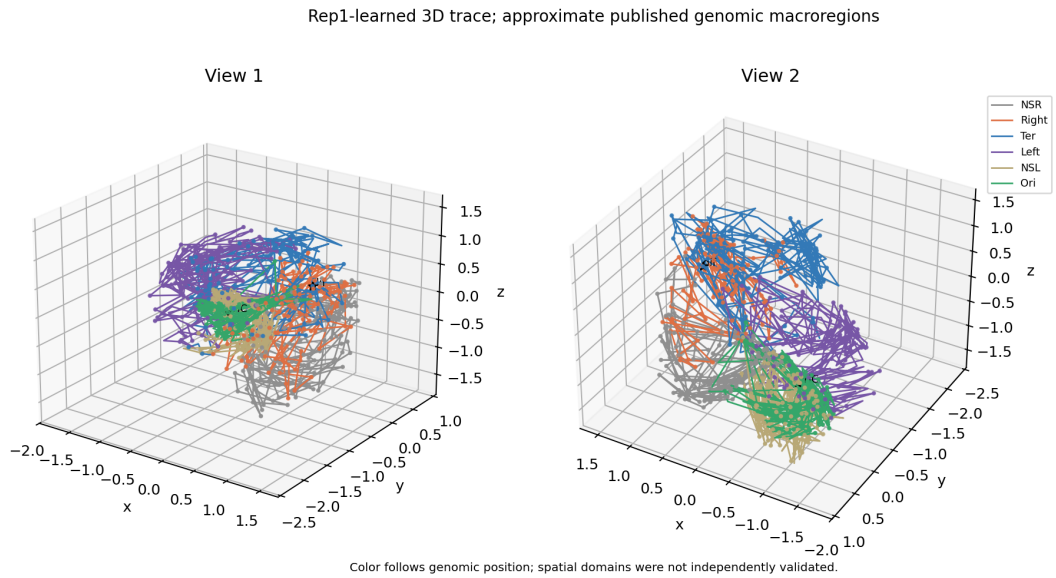


图 6. 学得的三维坐标与外部基因组宏区标签；颜色不证明真实空间分区。

复现与局限

`python -m pytest -q tests` 覆盖合成 `.cool` 的读取、归一化、候选管线、轨道、条件比较、超分辨与三维重建。真实数据指标、权重、坐标、代表性图和来源哈希在 `results/`。所有原始大矩阵位于被 Git 忽略的 `data/raw/`，下载脚本指向 GEO 官方记录。主要尚未解决的问题是 CHID 分类误报较多、候选数对阈值敏感、利福平深度差异大，以及超分辨和三维重建均缺少独立跨技术真值。